

Análise Tempo-Frequência de Sinais de Atividade Eletrodérmica

Paulo Victor M. R. Huguenin de Lima

Resumo—A atividade Eletrodérmica é usada como uma ferramenta para o diagnóstico médico de estados emocionais do indivíduo como estresse, ansiedade, medo, entre outros. Para identificar tais condições, é essencial processar esses sinais devido ao comportamento não estacionário. A análise de tempo-frequência dos sinais de EDA fornece a visualização correta para extrair as frequências que causam determinadas condições psicofisiológicas. Será visto neste trabalho se há ou não relação entre a frequência de um sinal EDA e a frequência cardíaca e serão usadas ferramentas de visualização tempo-frequência como STFT, Wigner-Ville e Wavelets para decisão de uma melhor abordagem para análise de sinais EDA.

Palavras-Chave—Atividade Eletrodérmica, Análise Tempo-Frequência, Matching Pursuit, STFT, WVD, Wavelets

I. INTRODUÇÃO

Neste trabalho, analisam-se sinais de EDA (Atividade Eletrodérmica) – um parâmetro psicofisiológico que é amplamente utilizado em avaliações médicas e saúde mental como nível de estresse, ansiedade, respostas emocionais (dor, alegria), em detectores de mentiras, dentre outros. A atividade eletrodérmica é responsável por medir a condutância da pele quando em contato ao um eletrodo devido às atividades das glândulas sudoríparas. Tal medição corresponde a uma resposta não cognitiva - resposta do organismo a atividade autônoma simpática -, ou seja, não pode ser controlada voluntariamente, sendo assim, um ótimo marcador para a aferição de emoções [1]. Alguns estudos usaram EDA para avaliar a função simpática durante o exercício. Quando os pacientes são submetidos a carga física, a amplitude do sinal de EDA aumenta conforme o aumento da taxa de suor [2]. Embora haja um evidente aumento no nível de EDA, as informações mais valiosas da EDA residem não apenas na pele em nível de condutância, mas também nos padrões oscilatórios [3]. No domínio do tempo, normalmente duas medidas são obtidas da EDA: a condutância da pele nível (SCL) e as respostas de condutância da pele não específicas (NS.SCRs). SCL (microsiemens, μS) é uma medida relacionada às mudanças lentas de EDA e é calculada como uma média de várias medições feitas durante um período específico. As respostas de condutância da pele (SCRs) são os eventos transitórios rápidos contidos nos sinais EDA. O índice NS.SCRs é calculado como o número de SCRs em um período de tempo.

Os estudos por sinais fisiológicos vem crescendo com avanços tecnológicos nos quais dispositivos e acessórios usados no cotidiano são capazes de captar e processar esses

sinais como ECG ou EDA através de sensores biométricos no intuito de verificar o estado de saúde de um paciente. Na área da saúde, por exemplo, esses sinais permitem monitorar as condições físicas e psicológicas de um paciente durante as atividades diárias [1].

Ao lidar com sinais não estacionários, ferramentas de descrição satisfatórias são obrigadas a abranger alguma dependência temporal das características dos sinais. Nos métodos mais amplamente usados, esses recursos são geralmente relacionados diretamente à frequência, dando origem aos métodos de tempo-frequência. Porém, ao lado desse aspecto da análise espectral o outro lado também pode ser interessante, por exemplo na ocorrência de componentes que são caracterizados por algumas extensões de tempo e locais desconhecidos. A este respeito, métodos desejados devem evidenciar seletivamente tais características em escalas de observação correspondentes: estes podem ser referidos como métodos de escala de tempo. Este artigo tem como objetivo avaliar a relação entre a frequência de um sinal EDA e a frequência cardíaca e usar ferramentas de visualização tempo-frequência como STFT, Wigner-Ville e Wavelets aplicados a sinais de EDA.

II. ATIVIDADE ELETRODÉRMICA

A atividade eletrodérmica (EDA) é o registro de alterações da resposta da condutância da pele (SCR - *Skin Conductance Response*) causadas, em grande parte, pela flutuação da atividade de glândulas sudoríparas. A Figura 1 ilustra um exemplo de sinal de EDA. Ela é altamente sensível a uma grande variedade de estados psicofisiológicos (atenção, processamento de informação, respostas emocionais, dor e excitação, etc) sendo capaz de revelar ocorrências de eventos psicologicamente marcantes [4]. Para adquirir o sinal de EDA (em μS – micro-Siemens) normalmente utilizam-se dois eletrodos em contato com a pele em pontas de dedos ou no pulso. Aplica-se uma tensão produzindo uma corrente elétrica pequena através do corpo. Contudo, a EDA registra ainda padrões não psicofisiológicos (atividade física aumentada, umidade, variações de temperatura) e pode ser corrompida ainda por ruído elétrico, e movimentos do dispositivo de medição [5]. Tais artefatos podem impedir avaliações psicofisiológicas por parte de especialistas, se não forem cuidadosamente tratados e removidos [6].

A análise de sinais de EDAs considera duas componentes [7]. A componente tônica corresponde à variação lenta, crescente ou decrescente, do nível de condutância da pele ao longo do tempo. Já a componente fásica corresponde a uma variação mais abrupta e está associada a resposta de




Fig. 1. Ilustração da medição de um sinal de EDA.

condutância da pele (SCR). Em geral, filtra-se a componente tônica do sinal de EDA que não fornece informação clara ou útil para diagnósticos de alteração psicológica. Assim, a análise de sinais de EDA é feita com a componente fásica. Ela contém padrões bem definidos (SCRs) compostos por três partes [5]: tempo de subida, pico da resposta, e meio período de recuperação. Observa-se que a subida é abrupta e o retorno à linha de base é razoavelmente lento. Para adultos saudáveis, o tempo de subida está normalmente entre 1 e 3 segundos, o limiar mínimo de pico está entre 0,01 e 0,05 μS , e o meio período de recuperação entre 2 e 10 segundos [5]. É possível ocorrerem SCRs compostos, um SCR surge antes da completa extinção do SCR anterior. Normalmente a banda da componente fásica de um sinal EDA varia de 0.045Hz a 0.5Hz. Como as componentes fásicas ocorrem geralmente de forma esparsa no tempo, mais ou menos a cada 2 minutos, nada mais adequado do que lançar mão de análises tempo-frequência para verificar o comportamento do sinal buscando alguma relação entre a frequência do sinal e algum estado psicológico do paciente.

A. Separação das Componentes do Sinal EDA

Devido à variação da componente tônica ser lenta, podemos usar uma regressão linear por métodos de Mínimos Quadrados (MMQ) [8] para obter uma reta que a represente. Para cada bloco do sinal x , encontra-se a reta que melhor se ajusta ao bloco impondo que a primeira amostra seja igual à última amostra da reta obtida para o bloco anterior. Portanto, há conexão entre as retas das componentes tônicas de blocos adjacentes. Por fim, subtrai-se a componente tônica aproximada do sinal original para obter a componente fásica.

III. AQUISIÇÃO DE DADOS

Neste trabalho, a base de dados de sinais EDA *Physionet* [9] (na qual é possível sinais fisiológicos complexos) é empregada. Foram extraídos dessa base 4 sinais de EDA com aproximadamente 38 minutos de duração cada, a taxa de amostragem é de 8 Hz. Paralelo a isso a frequência cardíaca também é extraída e é importante para verificar sua relação com o sinal EDA.

A configuração experimental para obter os sinais de EDA envolve 5 pessoas, em que foram solicitadas a realização de determinadas tarefas a fim de avaliar como o corpo humano de cada indivíduo se comporta a cada situação. As tarefas são realizadas na seguinte ordem [9]:

- 1) **Primeiro relaxamento:** Período de 5 minutos.

- 2) **Estresse físico:** Ficar de pé por 1 minuto, caminhar na esteira a 2 km/h por 2 minutos, em seguida, caminhar a 5 km/h por mais 2 minutos.
- 3) **Segundo relaxamento:** Período de 5 minutos.
- 4) **Estresse cognitivo:** Contar de trás para frente de 7 em 7, começando em 2485 por 3 minutos. Foi realizado também o teste de ler palavras com nomes de cores diferentes das cores apresentadas, dizendo-se assim a cor da palavra e não a cor de fato. Em ambos os testes, foi utilizado um alarme para avisar sobre o erro.
- 5) **Terceiro relaxamento:** Período de 5 minutos.
- 6) **Estresse emocional:** Assistir a um trecho de um filme de terror por um período de 5 minutos.
- 7) **Quarto relaxamento:** 5 minutos de duração.

Durante os quatro períodos de relaxamento, os voluntários foram solicitados a sentar-se confortavelmente e ouvir sons específicos usados para meditação ou concentração (*Binaural*). O objetivo do relaxamento entre as tarefas é estabelecer uma linha base para as medidas fisiológicas [9].

IV. STFT

A análise de Fourier decompõe um sinal em suas componentes de frequência e com ela temos a descrição do espectro do sinal durante todo o tempo. Definimos a transformada de Fourier como:

$$F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-j\omega t} dt \leftrightarrow f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega) e^{j\omega t} d\omega$$

A transformada de Fourier é aplicada a sinais estacionários, ou seja, suas propriedades não variam com o tempo. Quando tratamos de sinais não estacionários como o sinal EDA podemos introduzir um parâmetro para olharmos o sinal através de uma janela sobre a qual o sinal seja aproximadamente estacionário. [10] Portanto, em termos práticos o procedimento para calcular STFTs é dividir um sinal de tempo mais longo em segmentos mais curtos de igual comprimento e, em seguida, calcular a transformada de Fourier separadamente em cada segmento mais curto. Isso revela o espectro de Fourier em cada segmento mais curto. Em seguida, geralmente é feito um gráfico dos espectros variáveis em função do tempo, conhecido como espectrograma. Assim, podemos definir que a STFT é a transformada de Fourier do sinal multiplicado por uma função janela $g(t)$ conforme ela é deslizada ao longo do tempo. Podemos definir a STFT como [11]:

$$S_g(t, \omega) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} s(\tau) g(\tau - t) e^{-j\omega \tau} d\tau$$

Onde a escolha da janela $g(t)$ influencia na análise do sinal. O janelamento reduz a amplitude das descontinuidades nos limites de cada sequência finita adquirida pelo digitalizador [12]. O janelamento consiste em multiplicar o registro de tempo por uma janela de comprimento finito com uma amplitude que varia suave e gradualmente em direção a zero nas bordas. Isso faz com que os pontos finais da forma de onda se encontrem e, portanto, resulta em uma forma de onda contínua sem transições nítidas. Há diversas de funções janelas usuais e para

cada tipo de sinal há vantagens e desvantagens. Para entender como uma determinada janela afeta o espectro de frequência, é necessário entender mais sobre as características de frequência das janelas. Um gráfico real de uma janela mostra que a característica de frequência de uma janela é contínua no espectro com um lobo principal e vários lobos laterais. O lóbulo principal é centrado em cada frequência componente do sinal no domínio do tempo, e os lóbulos laterais se aproximam de zero. A altura da lateral lóbulos indica o efeito que a função de janelas tem nas frequências ao redor dos lóbulos principais. Normalmente, os lobos laterais inferiores reduzem o vazamento no FFT medido, mas aumentar a largura de banda do lóbulo principal. Selecionar uma função de janela não é uma tarefa simples. Cada função da janela tem seu próprio características e adequação para diferentes aplicações.

Essas funções de janela são úteis para medições de ruído onde melhor frequência resolução do que algumas das outras janelas é desejada, mas lobos laterais moderados não apresentar um problema.

Normalmente, quando queremos visualizar graficamente o espectro em torno de um instante t ou o comportamento no tempo em torno de uma frequência ω usamos o espectrograma que é o módulo da STFT ao quadrado[11].

$$|S_g(t, \omega)|^2 = \left| \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} s(\tau) g(\tau - t) e^{-j\omega\tau} d\tau \right|^2$$

Pela fórmula acima, parece que um espectrograma não contém informações sobre a fase exata, ou mesmo aproximada, do sinal que ele representa. Por este motivo, não é possível reverter o processo e gerar uma cópia do sinal original a partir de um espectrograma, embora em situações onde a fase inicial exata não seja importante, pode ser possível gerar uma aproximação útil do sinal original. O tamanho e a forma da janela de análise podem ser variados. Uma janela menor (mais curta) produzirá resultados mais precisos na temporização, às custas da precisão da representação da frequência. Uma janela maior (mais longa) fornecerá uma representação de frequência mais precisa, em detrimento da precisão na representação de tempo. Este é um exemplo do princípio da incerteza de Heisenberg, de que o produto da precisão em duas variáveis conjugadas é maior ou igual a uma constante ($B * T \geq 1$). [10]

V. WIGNER-VILLE

A função de distribuição de Wigner (WVD) é usada no processamento de sinais como uma transformação na análise de tempo-frequência. O WDF foi proposto pela primeira vez na física para explicar as correções quânticas da mecânica estatística clássica em 1932 por Eugene Wigner e sua aplicação para processamento de sinais foi desenvolvida por Ville. A WVD de um sinal $s(t)$ pode ser definida como[11]:

$$WVD_s(t, \omega) = \frac{1}{2\pi} \int_{-\infty}^{\infty} s\left(t + \frac{\tau}{2}\right) s^*\left(t - \frac{\tau}{2}\right) e^{-j\omega\tau} d\tau$$

A WVD também é conhecida como uma distribuição bilinear ou quadrática pois dado um sinal $s(t)$ aparece duas vezes em sua definição.

Comparada a uma transformada de Fourier de curto tempo, como a transformada de Gabor, a função de distribuição de Wigner fornece a mais alta resolução temporal vs frequência que é matematicamente possível dentro das limitações da incerteza na teoria das ondas quânticas. Além disso, a distribuição Wigner-Ville é visualmente distinta do espectrograma e muito mais custoso computacionalmente. Para gerar um espectrograma WDF de amostra precisa (1024 bandas) em tempo real, seriam necessários cerca de 16 núcleos de um PC de mesa moderno[13]. As propriedades da WVD são resumidos e reinterpretados com esta nova formulação da seguinte forma: (i) a WVD é uma função com valor real; (ii) a integral do WDF em relação à frequência e ao tempo produz o sinal instantâneo potência e densidade espectral de potência do sinal respectivamente; (iii) uma mudança de tempo ou frequência no sinal tem a mesma mudança no WDF; (iv) a WVD é simétrica no tempo e na frequência para um determinado sinal; (v) o WDF nem sempre é positivo; (vi) a integração do quadrado do WDF é igual ao quadrado da integração de tempo do sinal; (vii) a WVD satisfaz as propriedades marginais, o que nos informa que outras médias globais como tempo e frequência média, duração, banda e o princípio da incerteza também são satisfeitas, ou seja, obtém-se os mesmos resultados que seriam obtidos realizando cálculos diretamente ao sinal ou espectro. Devido a WVD ser uma transformada não linear muitos dos grandes problemas que precisamos lidar quando usamos a WVD são os termos cruzados. quando temos um sinal formado por uma soma de componentes tende a aparecer artefatos no espectro. Normalmente, sinais em não podemos definir através de uma função específica como o sinal de EDA, tende a apresentar termos cruzados quando realizamos a WVD. Para contornar este problema dos termos cruzados podemos fazer uso da estratégia de decompor um sinal $s(t)$ como uma combinação linear de funções pré-definidas[14].

$$s(t) \approx \sum_i \alpha_i g_{\gamma(i)}(t)$$

Sendo que cada $g_{\gamma(i)}(t)$ é um elemento diferente e fazemos uma análise do conteúdo tempo-frequência de $s(t)$ através de

$$\widehat{WVD}_s(t, \omega) \approx \sum_i \alpha_i^2 WVD_{g_{\gamma(i)}}(t, \omega)$$

Outro procedimento para reduzir o problema dos termos cruzados é usando a Wigner-Ville janelada, conhecida como Pseudo-Wigner-Ville. A P-WVD é ideal quando deseja-se enfatizar as propriedades de uma vizinhança para um t específico. A P-WVD pode ser definida como:

$$P-WVD_{s,g}(t, \omega) = \frac{1}{2\pi} \int_{-\infty}^{\infty} g(\tau) s\left(t + \frac{\tau}{2}\right) s^*\left(t - \frac{\tau}{2}\right) e^{-j\omega\tau} d\tau$$

onde $g(\tau)$ pondera as contribuições dos diferentes τ

VI. DECOMPOSIÇÃO DE ATÔMICA DE SINAIS DE EDA

As decomposições atômicas têm como objetivo selecionar um subconjunto de elementos (átomos ou estruturas) - de um dicionário de formas de onda pré-definidas - a fim de aproximar um sinal usando uma combinação linear desses elementos. Considerando o dicionário D composto de átomos

\mathbf{g}_γ , um sinal \mathbf{x} é aproximado usando M via

$$\mathbf{x} \approx \hat{\mathbf{x}} = \sum_{i=1}^M \alpha_i \mathbf{g}_{\gamma(i)}, \quad \mathbf{g}_{\gamma(i)} \in D \quad (1)$$

Os átomos $\mathbf{g}_{\gamma(i)}$ são indexados por $\gamma(i)$, e $\gamma : \mathbb{Z}^+ \rightarrow \{1, \dots, \#D\}$, $\#D$ é a cardinalidade – o número de elementos do dicionário D e portanto $\gamma(i) \in \{1, \dots, \#D\}$. O parâmetro α_i é o coeficiente que pondera $\mathbf{g}_{\gamma(i)}$.

Decomposições atômicas permitem modelar sinais com distorção pequena, acurada, compacta e coerentemente [15], [16]. O algoritmo utilizado neste trabalho para obter essas decomposições é o *Matching Pursuit* (MP) que realiza aproximações sucessivas de sinais, buscando em um dicionário redundante a melhor aproximação a cada iteração [10].

A. Dicionário de Bateman

A escolha das funções protótipo que compõem o dicionário depende das características da classe de sinais a decompor. Deve-se utilizar elementos que sejam coerentes ou similares aos fenômenos ou padrões existentes no sinal alvo. A literatura aponta uma significativa correlação entre as funções de *Bateman* e os padrões presentes em EDAs [17], [18], [19].

O dicionário de Bateman é composto por átomos bi-exponenciais dadas por

$$g_\gamma(n) = K_\gamma(e^{-\rho(n-\tau)} - e^{-\eta(n-\tau)}) \times \cos(\phi), \quad (2)$$

onde $\gamma = (\rho, \eta, \tau, \phi)$ é o conjunto de parâmetros definidores do átomo, sendo η o crescimento, ρ o decaimento ($\eta > \rho$), τ o deslocamento, ϕ a fase; acima, K_γ é um fator de normalização.

VII. TRANSFORMADA DE Wavelet CONTÍNUA(CWT)

A transformada de *wavelet* contínua é uma das ferramentas mais usadas para análise tempo-frequência de sinais não estacionários com o objetivo de saber o conteúdo de frequência variante no tempo. A CWT fornece uma representação tempo-frequência de um sinal, permitindo a escala das wavelets variem continuamente[20].

A CWD de um sinal $x(t)$ em uma escala ($a > 0$) e o parâmetro de translação b pode ser definida da seguinte forma:

$$X_w(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t) \psi^*\left(\frac{t-b}{a}\right) dt$$

Onde, $\psi^*(t)$ representa a Wavelet mãe, na qual representa uma função de origem capaz de gerar wavelets filhas, que são versões da wavelet mãe transladada e escalada com o objetivo de recuperar o sinal original. Há uma listas de tipos de *wavelets* mãe que podem ser usadas para análise tempo-frequência. Neste trabalho iremos fazer uma comparação com 2 tipos delas a fins de comparação: Morse, Morlet (Gabor).

A. Morse Wavelet

As wavelets de Morse generalizadas são uma família de wavelets exatamente analíticas. As wavelets analíticas são wavelets de valores complexos cujas transformadas de Fourier são suportadas apenas no eixo real positivo. Eles são úteis para analisar sinais modulados, que são sinais com amplitude

e frequência variáveis no tempo. Eles também são úteis para analisar descontinuidades localizadas. A transformada de Fourier da wavelet de Morse generalizada é:

$$\psi_M(\omega) = U(\omega) a_{P,\gamma} \omega^{\frac{P^2}{c}} e^{-\omega^c}$$

Onde $U(\omega)$ é a etapa unitária, $a_{P,\gamma}$ é uma constante de normalização, P^2 é o produto tempo-largura de banda, e c caracteriza a simetria da wavelet de Morse[21][22].

B. Morlet(Gabor)

A wavelet de Morlet ou Gabor é composta de exponenciais complexas janelada por uma função Gaussiana(envelope) e pode ser definida como[23]

$$\psi_G(t) = c\pi^{-\frac{1}{4}} e^{-\frac{1}{2}t^2} (e^{j\sigma t} - k_\sigma)$$

Onde $K_\sigma = e^{-\frac{1}{2}\sigma^2}$ e a constante de normalização $c_\sigma = \left(1 + e^{-\sigma^2} - 2e^{-\frac{3}{4}\sigma^2}\right)$ e sua transformada pode ser dada como:

$$\psi_G(\omega) = c\pi^{-\frac{1}{4}} \left(e^{-\frac{1}{2}(\sigma-\omega)^2} - k_\sigma e^{-\frac{1}{2}\omega^2}\right)$$

VIII. EXPERIMENTOS E RESULTADOS

A leitura, processamento e análise dos sinais EDA usando as ferramentas mencionadas nas seções anteriores foram desenvolvidas neste trabalho usando o software MATLAB®. O objetivo é verificar se há alguma relação entre a frequência e amplitude do sinal EDA com o estado físico e emocional em que o paciente se encontra. Além disso, deseja-se comparar diversas ferramentas de análise tempo-frequência, buscando avaliar qual ferramenta é a mais adequada para a aplicação.

Para avaliar a relação entre a frequência do sinal e o estado emocional do paciente em cada tarefa, segmentou-se o sinal em 7 trechos referentes a cada tarefa para todos os sinais analisados. Em seguida realizou-se a média da frequência máxima(Frequência superior considerando 95% da banda) e da frequência média dos sinais. A figura 2 ilustra esses espectros separados por esses eventos. Sabendo que os segmentos ímpares são dados por momentos de relaxamento e os pares envolvendo algum tipo estresse físico, cognitivo ou emocional. Destaca-se que para o momento de estresse físico há maiores valores de frequência média e máxima enquanto que para as etapas de relaxamento há uma queda. É possível visualizar em que momento no tempo há aumento e diminuição de frequência usando as ferramentas vistas.

A. STFT

Foi visto na seção IV a importância do janelamento e que a escolha da janela e da taxa de janelamento interferem na análise do sinal. Com isso, realizou-se alguns testes para ajudar na decisão dos melhores parâmetros da janela. A primeira avaliação é quanto a taxa de janelamento e ao tamanho da janela. Foi visto que quanto maior é a taxa de janelamento e menor é o tamanho da janela maior é sua resolução no tempo e consequentemente menor na frequência. A figura 3 mostra em como uma janela menor(256 amostras) apresenta uma melhor

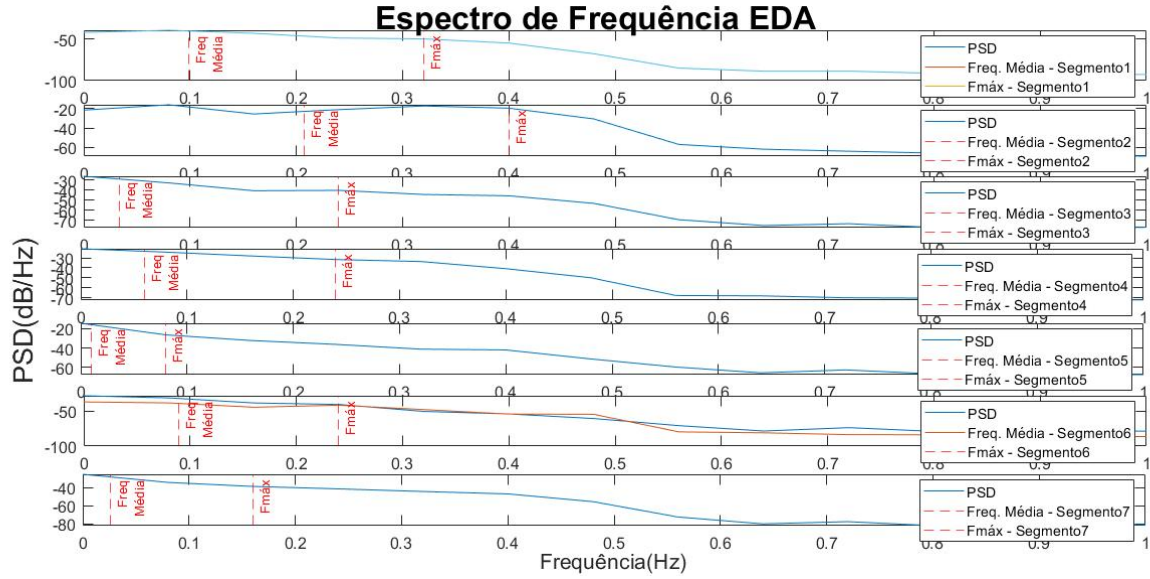


Fig. 2. Espectro de Frequência do sinal de EDA segmentado para diversos eventos e com frequência média e máxima computadas.




Fig. 3. Espectrograma de um sinal EDA variando o tamanho da janela

resolução no tempo que uma janela maior(1024 amostras). Em contrapartida, poderíamos perder algumas componentes de frequência. A segunda avaliação seria em qual janela utilizar. Vimos que há diversas possibilidades de funções janela e que cada janela possui características que as diferem. A figura 5 apresenta o espectrograma para 4 janelas diferentes(Retangular, Hann, Hamming e FlatTop). A janela retangular foi a que obteve a pior resolução no tempo e apresentou um vazamento espectral maior. A janela FlatTop obteve uma boa resolução no tempo, mas na frequência apresentou pior resolução. As janelas de Hamming e Hann obtiveram desempenhos parecidos quanto a resolução no tempo e frequência e foram que apresentaram melhor equilíbrio para analisar o sinal. Porém, a janela de Hamming obteve um vazamento espectral um pouco maior do que a de Hann. Com isso, de maneira geral, a janela de Hann obteve um melhor resultado visual quando comparada as outras analisadas. A figura 4 apresenta o espectrograma do sinal de EDA e o batimento cardíaco do paciente durante os eventos. Nota-se que tanto a frequência quanto a amplitude de um sinal EDA está ligada a frequência cardíaca. Quando a frequência cardíaca aumenta há a tendência da frequência do sinal EDA aumentar também e com isso o estado físico e emocional do indivíduo.

Pelos espectros apresentados vimos que as componentes de frequência estão concentradas em até 0,5Hz e mesmo quando tentou-se melhorar ao máximo a resolução em frequência não foi possível distinguir tão bem as frequências nesta faixa.

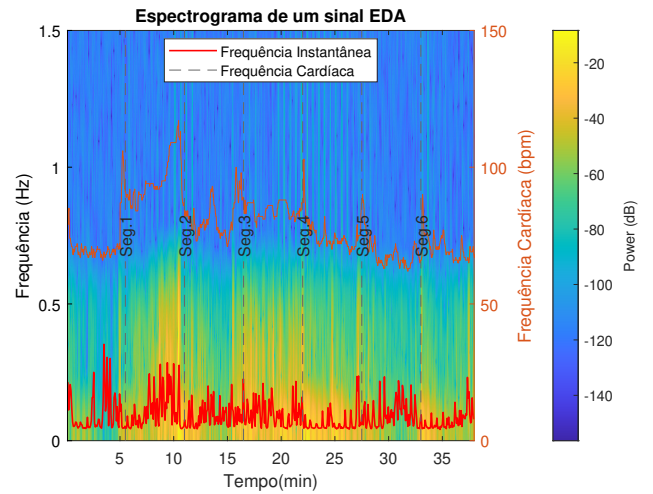


Fig. 4. Espectrograma de um sinal EDA, frequência instantânea e frequência cardíaca.

B. WVD

Na seção V foi apresentado outra ferramenta para análise tempo frequência e vimos que é possível minimizar os termos cruzados de um sinal composto por mais de uma componente realizando a decomposição atômica do sinal e a P-WVD. Por ser muito custosa computacionalmente não foi possível realizar a WVD para o sinal todo. Uma solução para isso foi usando a decomposição atômica apresentada na seção VI onde foi possível realizar a WVD dos átomos obtidos na decomposição e em seguida somá-los. A figura 7 ilustra

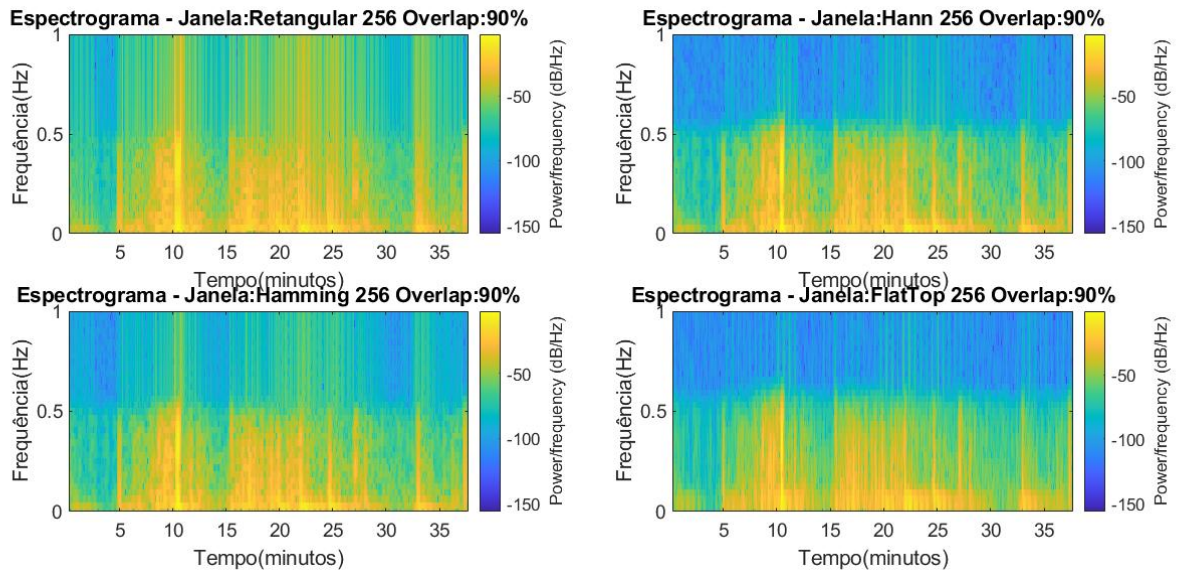


Fig. 5. Espectrograma para 4 Janelas(Retangular, Hann , Hamming, Flatop)

a WVD do sinal completo usando decomposição atômica. Comparando com o espectrograma usando STFT podemos observar ambos são semelhantes quanto a resolução no tempo, porém a WVD consegue diferenciar melhor a frequência uma das outras. Apesar disso há um vazamento espectral grande em instantes de tempo com maiores intensidades, apresentando frequências bem acima das reais. Isso pode ser devido as características da função de Bateman utilizada no algoritmo Matching Pursuit. Pela figura 8 foi possível comparar 3 modos de calcular a WVD para um trecho de um sinal de EDA. Com os 3 modos foi possível encontrar os pontos de maior intensidade do sinal bem destacado no tempo. Vimos que usando a soma das WVDs dos átomos que compõe o sinal é possível chegar próximo a WVD do sinal. Comparando a WVD convencional com a P-WVD vemos o espectro mais claro e melhor definido. O janelamento gerado pela P-WVD acabou por reduzir os termos cruzados.

C. CWT

Da mesma forma, aplica-se agora a CWT para diferentes Wavelets mãe e analisa-se a escolha delas. A figura 6 ilustra o escalograma para o sinal EDA usando Wavelet Morse para 2 valores de tempo-banda (60 e 10) e mantendo $\gamma = 3$ (garante a simetria). Usando tempo-banda=60 obtemos uma resolução tempo frequência equilibrada, enquanto que se diminuirmos o parâmetro tempo-banda=10 observa-se que ganhamos resolução no tempo e perdemos na frequência. É possível notar que diferentemente da STFT e WVD há diferenças de resolução conforme varia-se a frequência. Temos para baixas frequências uma maior resolução na frequência, enquanto que para o tempo perde-se resolução. Comparando agora as Wavelets mãe utilizadas, percebe-se tanto a Morse quanto a Morlet(Gabor) não há diferenças visuais perceptíveis para a análise tempo-frequência. Já a Wavelet Bump apresenta baixa resolução no tempo o que vai de contra ao objetivo.

IX. CONCLUSÕES

Neste trabalho, apresentou-se uma análise em tempo-frequência de sinais de EDA usando diversas ferramentas que possibilitam a visualização dos dois domínios simultaneamente. Sendo assim possível como as componentes de frequência de um sinal se comporta durante o tempo. Além disso, vimos que as intensidades e frequências de um sinal EDA está ligada a frequência cardíaca, podendo ser assim de grande valia para extração de atributos atrelado a reconhecimento de padrões. Com a realização da análise por STFT de janelas concluiu-se que uma boa opção para janelamento é usar a janela de Hann e tamanhos de janelas menores caso queira obter uma maior resolução no tempo. Usando a WVD foi observado que podemos usar a soma de WVDs dos átomos de um sinal decomposto usando Matching Pursuit obtendo uma boa representação e com redução dos termos cruzados. Além disso, vimos que a P-WVD é uma boa opção para análise pois obteve um resultado com uma redução considerável dos termos cruzados. Para Wavelets vimos em como sua resolução varia com a frequência e o tempo. Por se tratar de um sinal com frequências muito baixas, perdeu-se muita resolução no tempo o que não é o desejado para esta aplicação. Entre as Wavelets analisadas vimos que a Morse e Morlet obtiveram desempenho semelhante.

REFERÊNCIAS

- [1] A. Greco, G. Valenza, and E. Scilingo, "Advances in electrodermal activity processing with applications for mental health," *Advances in Electrodermal Activity Processing with Applications for Mental Health: From Heuristic Methods to Convex Optimization*, 01 2016.
- [2] M. N. Sawka, C. B. Wenger, and K. B. Pandolf, "Thermoregulatory responses to acute exercise-heat stress and heat acclimation," *Comprehensive physiology*, pp. 157–185, 2010.
- [3] J. Rittweger, M. Lambertz, and P. Langhorst, "Electrodermal activity reveals respiratory and slower rhythms of the autonomic nervous system," *Clinical Physiology*, vol. 16, no. 3, pp. 323–326, 1996.
- [4] T. L. B. G. E. Cacioppo, J., *Handbook of Psychophysiology*, 3rd ed. Cambridge University Press, 2007.

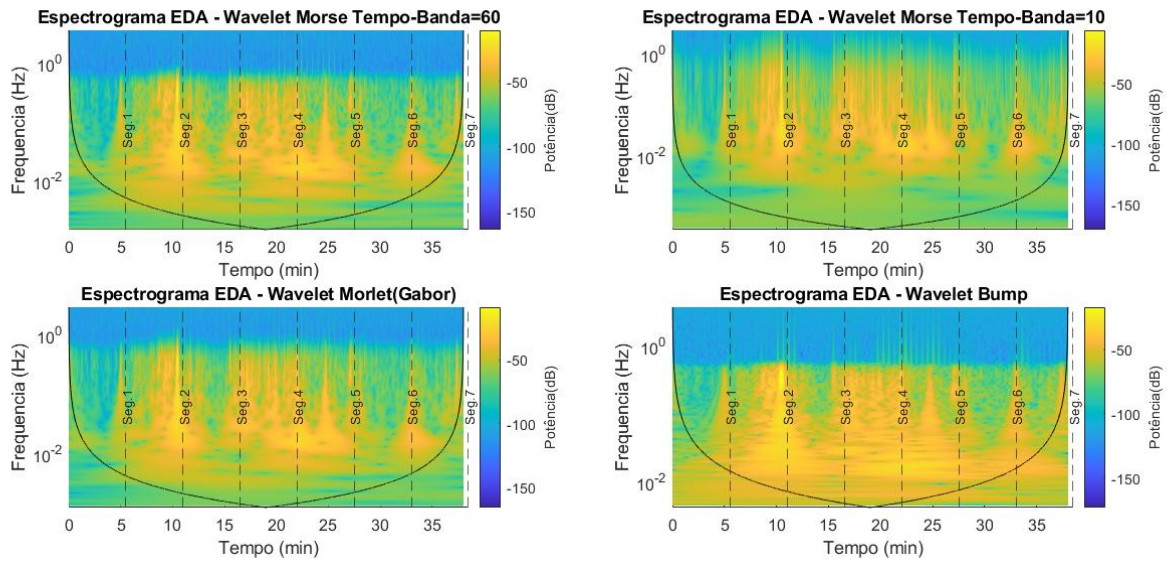


Fig. 6. CWT para 4 tipos de wavelet mãe(Morse60, Morse10 , Morlet, Bump)

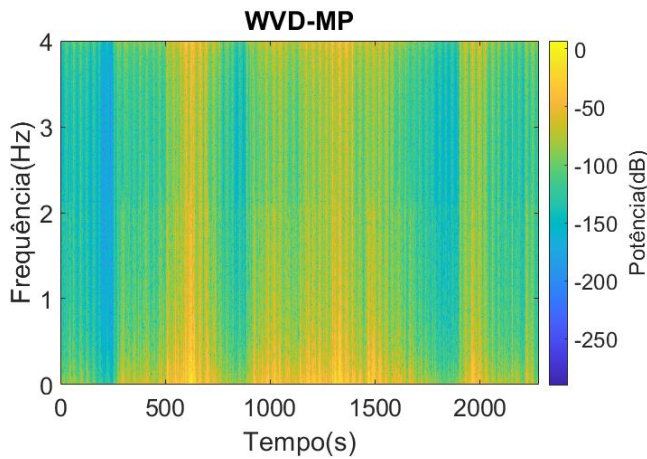


Fig. 7. WVD para um sinal EDA usando decomposições atômicas

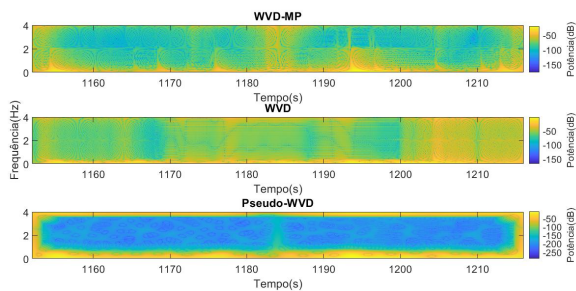


Fig. 8. WVD usando Matching Pursuit, WVD e P-WVD de um sinal EDA

[5] W. T. Roth, M. E. Dawson, and D. L. Fillion, "Publication recommendations for electrodermal measurements," *Psychophysiology*, vol. 49, no. 8, pp. 1017–1034, 2012.

[6] L. G. T. Dawson and G. Bernston, *The Electrodermal System(Eds)-Handbook of Psychophysiology (2nd Ed)*. Cambridge University Press, 2001.

[7] A. Greco, G. Valenza, and E. P. Scilingo, *Advances in Electrodermal*

Activity Processing with Applications for Mental Health: From Heuristic Methods to Convex Optimization. Springer, 2016.

[8] G. H. Golub and C. F. Van Loan, *Matrix Computations (3rd Ed.)*. Baltimore, MD, USA: Johns Hopkins University Press, 1996.

[9] D. C. M. B. P. Birjandtalab, Javad and M. Nourani, "A non-ecg bio-signals dataset for assessment and visualization of neurological status," *SiPS 2016*, pp. 110–114, 2016.

[10] S. Mallat, *A Wavelet Tour of Signal Processing*, 2nd ed. California, USA: Academic Press, 1998.

[11] L. Cohen, *Time-frequency analysis*. Prentice Hall PTR Englewood Cliffs, NJ., 1995, vol. 778.

[12] E. Sejdić, I. Djurović, and J. Jiang, "Time–frequency feature representation using energy concentration: An overview of recent advances," *Digital signal processing*, vol. 19, no. 1, pp. 153–183, 2009.

[13] N. Yen, "Time and frequency representation of acoustic signals by means of the wigner distribution function: Implementation and interpretation," *The Journal of the Acoustical Society of America*, vol. 81, no. 6, pp. 1841–1850, 1987.

[14] S. Mallat and Z. Zhang, "Matching pursuits with time-frequency dictionaries," *IEEE Transactions on Signal Processing*, vol. 41, no. 12, pp. 3397–3415, Dez. 1993.

[15] L. Lovisolo, E. A. B. da Silva, M. A. M. Rodrigues, and P. S. R. Diniz, "Efficient coherent adaptive representations of monitored electric signals in power systems using damped sinusoids," *IEEE Transactions on Signal Processing*, vol. 53, no. 10, pp. 3831–3846, 2005.

[16] M. P. Tcheou, "Compressão de sinais usando decomposições atômicas," Tese de Doutorado, PEE/COPPE,UFRJ, Rio de Janeiro, Brasil, 2011.

[17] M. Kelsey, M. Akcakaya, I. Kleckner, R. Palumbo, L. Barrett, K. Quigley, and M. Goodwin, "Applications of sparse recovery and dictionary learning to enhance analysis of ambulatory electrodermal activity data," *Biomedical Signal Processing and Control*, vol. 40, pp. 58–70, 02 2018.

[18] T. Chaspari, A. Tsiartas, L. I. Stein, S. A. Cermak, and S. S. Narayanan, "Sparse representation of electrodermal activity with knowledge-driven dictionaries," *IEEE Transactions on Biomedical Engineering*, vol. 62, no. 3, pp. 960–971, March 2015.

[19] G. Oliveira and M. P. Tcheou, "Análise da decomposição de sinais de atividade eletrodérmica em múltiplos dicionários usando algoritmos vorazes," *SBRT2018*, vol. 1, p. 5, 2018.

[20] S. Mallat, *A wavelet tour of signal processing: the sparse way*. Academic press, 2008.

[21] S. C. Olhede and A. T. Walden, "Generalized morse wavelets," *IEEE Transactions on Signal Processing*, vol. 50, no. 11, pp. 2661–2670, 2002.

[22] J. M. Lilly and S. C. Olhede, "Higher-order properties of analytic wavelets," *IEEE Transactions on Signal Processing*, vol. 57, no. 1, pp. 146–160, 2008.

[23] J. Ashmead, "Morlet wavelets in quantum mechanics," *arXiv preprint arXiv:1001.0250*, 2010.